



Sommaire

- 1. Introduction
- 2. Modèles utilisés
- 3. Résultats
- 4. Conclusion et perspectives



1. Introduction



Récents progrès en génération de texte SeqtoSeq (2014), transformeur (2017)



Ancien président américan très actif sur tweeter



Langage simple et peu structuré



1. Données

52 183

Nombre de tweets utilisés



Nettoyage de la données

- Suppression des retweets pour les deux premiers modèles que nous avons utilisé
- Texte minuscule



- Tokenisation des mots du datasets
- Utilisation de la librairie de représentations vectorielles pré-entrainées du sens des mots, Fasttext



2. Modèles utilisés

LSTM

GRU

Markov GPT2

avec attention

Chain

-Architecture de réseau de neurones récurrents -Représentation vectorielles des mots

- -Architecture de réseau de neurones récurrents -Représentation vectorielles des mots -Mécanisme d'attention
- -Modèle statistique -Entroîné sur les caractères

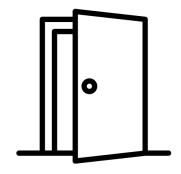
-Modèle de langue pré-entraîné -Architecture basée sur le transformeur



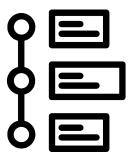
2. Recurrent Neural Networks de type LSTM et GRU



LSTM et GRU pallie au problème d'evanescence du gradient



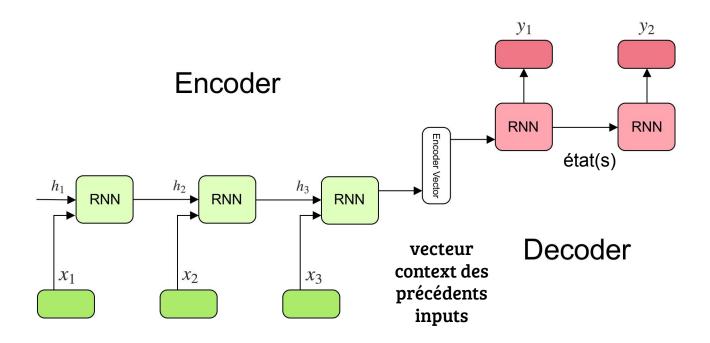
Utilise un système de portes et d'état(s) pour stocker et transférer le "contexte"



Utile quand il existe de l'information dans l'ordonnancement des données et le sens de lecture (time series, texte)



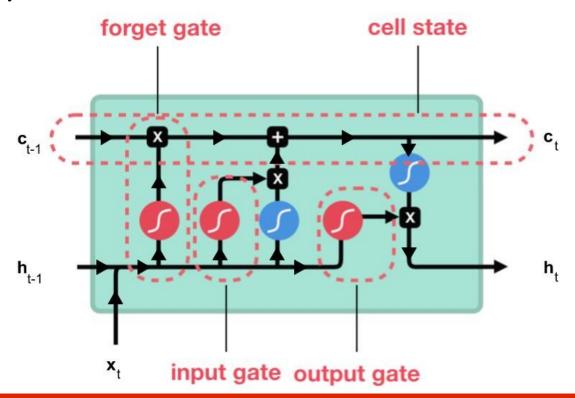
2. Architecture encodeur-décodeur





2. LSTM





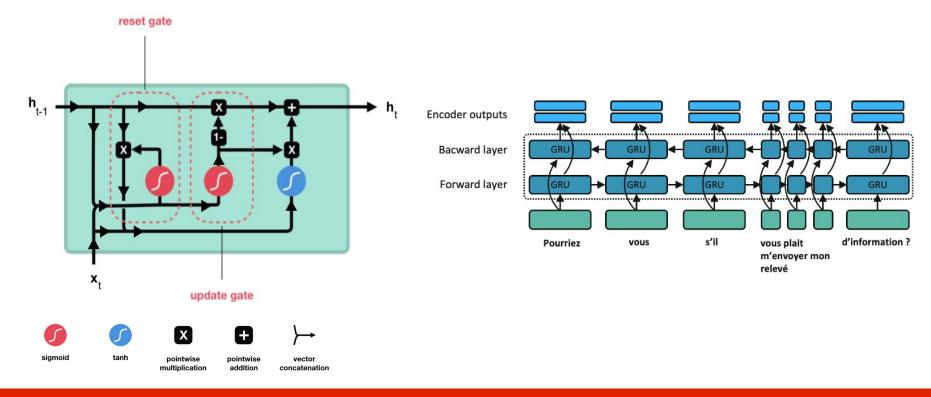


2. LSTM résultats

Entrée	Sortie
"barack obama is the"	"worst president in the world. all of the world is laughing at the same time?"
"71 000 000 votes incredible"	"- we are going to win !"
"thanks to all of you"	"to the great state of texas. i will be a great governor of montana!"

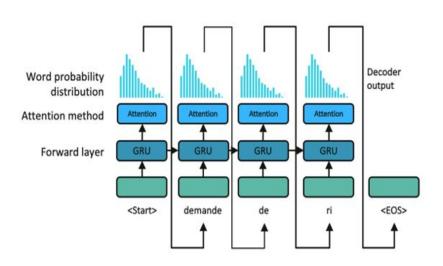


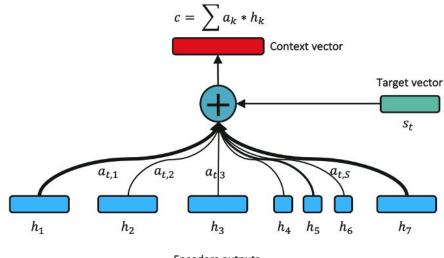
2. GRU avec mécanisme d'attention





2. GRU avec mécanisme d'attention



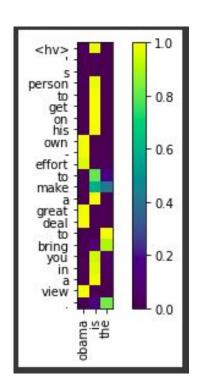


Encoders outputs



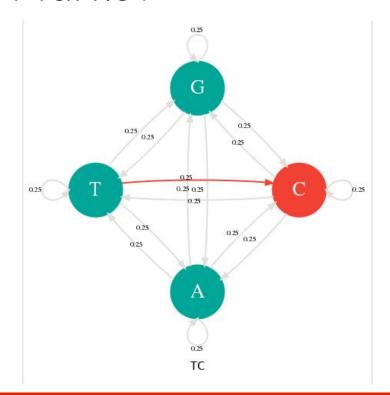
2. GRU, résultats

Entrée	Sortie
"obama is"	" <hv> 's person to get on is own - effort to make a great deal to bring you in a view."</hv>
"we need that for the"	" @ <hv> speech on your passing the # <hv> . we need it!"</hv></hv>
"my people are"	"for all the @ god party 's card - a great commodity is a terrific person."





2. Chaîne de Markov



-N-grammes

-Fréquence d'apparition par rapport aux n-gramme



2. Chaîne de Markov, résultats

n-gramme initial	longueur du n-gramme	longueur du tweet	Sortie
"Hill"	4	70	"Hillars they way use othere of in the phone who do sold at @Trump. Nice.If"
"Hillary"	7	65	"Hillary Clinton like him! I will never given? RT @newtgingrich on an int"
"Barack Obama"	12	50	"Barack Obama was president! RT @tashlutsa: @CLewandowski_: Wat"

-Sens sémantique limité -Présence des RT -Présences de compte tweeter réels



2. Modèles de langues pré-entraînés, GPT2

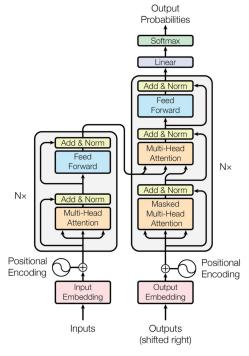
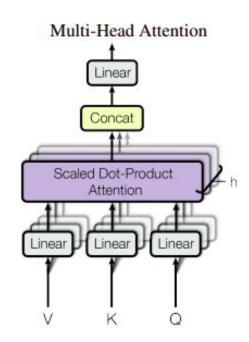
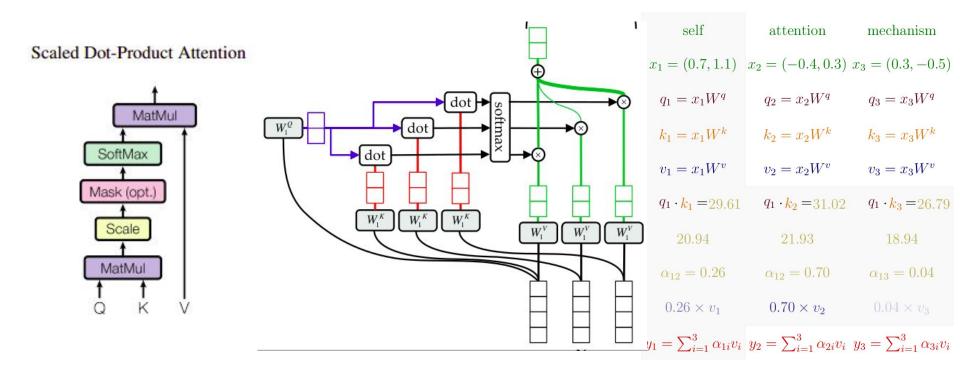


Figure 1: The Transformer - model architecture.





2. Modèles de langues pré-entraînés, GPT2



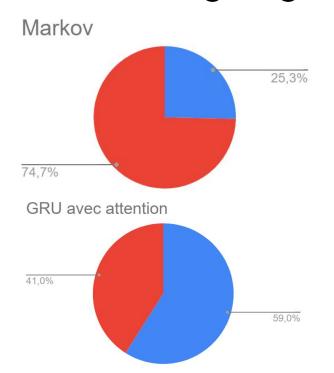


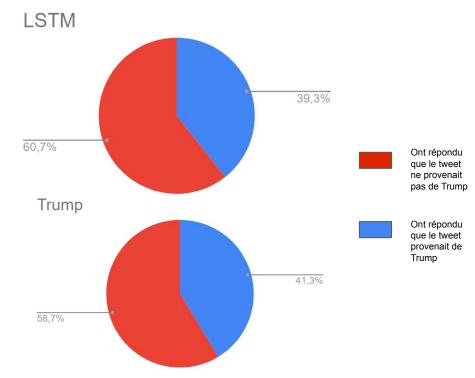
2. Résultats de GPT2

Entrée	Sortie
Barack Obama and democrats	"Barack Obama and democrats can't get their waywe're at a standstill', 'Congressman Mike Crapo (@CumpoGOP) has been an incredible advocate for America and has my Complete and Total End"
"Joe"	'Joe. My time is going to come when I'm 100% there and you will WIN!'
"Thank to our"	'Thank to our beautiful @GOPleaders', 'RT @TomFitton: "Senator Mark Warner did an amazing job on Fox & Description on Your new book. You are the man for it but you still"
sleepy Joe	'sleepy Joe Biden? He is also a totally stupid person!



3. Résultats google form





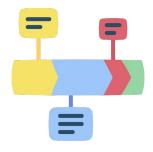


Conclusion et perspectives









Expérience pratique

Réelle avantage de l'attention

Nous aurions voulu explorer plus les modèles langues pré-entraînés et inclure les résultats au formulaire soumis aux étudiants

Découper le jeu de données en fonction des périodes de la présidence de Donald Trump.





Avez-vous des questions?

